Politechnika Warszawska
Wydział Matematyki i Nauk Informacyjnych

Projekt 1: Klasyfikacja i regresja z użyciem perceptronu

Przedmiot: Sieci Neuronowe

Autorzy:
Krzysztof Radzewicz
Jakub Rak

Prowadzący:
[mgr. inż. Mikołaj Małkiński]

Warszawa, 27 października 2026

Spis treści

1 Wstęp i cel projektu **1**

2 Implementacja wielowarstwowego perceptronu (MLP) **1**

3 Eksperymenty — Zagadnienie regresji **1**
3.1 Zbiory danych i metodyka badawcza 1
3.2 Wpływ funkcji aktywacji w warstwach ukrytych 3
3.3 Wpływ architektury sieci: głębokość i szerokość 5
3.4 Wpływ miary błędu (funkcji straty) 6
3.5 Wpływ rozmiaru zbioru danych (opcjonalnie) 8
3.6 Podsumowanie i wnioski z części regresyjnej 8

4 Eksperymenty — Zagadnienie klasyfikacji **9**
4.1 Zbiory danych 9
4.2 Eksperyment 1 - Funkcje aktywacji w warstwach ukrytych 10
4.2.1 Zbiór danych simple 10
4.2.2 Zbiór danych three_gauss 11
4.3 Eksperyment 2 - Architektura sieci 13
4.3.1 Zbiór danych simple 13
4.3.2 Zbiór danych three_gauss 14
4.4 Eksperyment 3 - Wpływ funkcji straty 15
4.4.1 Zbiór danych simple 16
4.4.2 Zbiór danych three_gauss 17
4.5 Podsumowanie i wnioski z części klasyfikacyjnej 19

5 Podsumowanie ogólne i wnioski końcowe **19**

1 Wstęp i cel projektu

Celem niniejszego projektu jest samodzielna implementacja wielowarstwowego perceptronu (*Multilayer Perceptron*, MLP) od podstaw z wykorzystaniem wyłącznie biblioteki `NumPy`. W ramach implementacji, przygotowano algorytm wstecznej propagacji błędu oraz stochastycznego spadku gradientu (*Stochastic Gradient Descent*). Przygotowany model posłużył do rozwiązania zagadnień aproksymacji nieliniowej dla funkcji $\mathbb{R} \to \mathbb{R}$ (zadanie regresji) oraz przydzielania klas punktom w przestrzeni $\mathbb{R}^2$ (zadanie klasyfikacji binarnej i wieloklasowej). W ramach pracy zbadano kilka aspektów wpływających na działanie sieci, takich jak dobór funkcji aktywacji (Sigmoid, Tanh, ReLU), głębokości i szerokości architektury (od 0 do 4 warstw ukrytych) oraz zastosowanych miar błędu na wyjściu modelu (MSE, BCE, CCE).

2 Implementacja wielowarstwowego perceptronu (MLP)

Kod źródłowy został podzielony na następujące moduły:

- **layers** — definiuje klasę bazową warstwy oraz warstwę w pełni połączoną (`Dense`), odpowiedzialną za transformację liniową, przechowywanie wag i biasów, a także inicjalizację wag przy pomocy zdefiniowanych rozkładów [1].
- **activations** — zawiera implementacje funkcji aktywacji (`ReLU`, `Sigmoid`, `Tanh`, i `Softmax`) wraz z metodami wyznaczania ich pochodnych na potrzeby propagacji wstecznej.
- **losses** — zawiera implementacje funkcji straty: błąd średniokwadratowy (`MSE`), binarna (`BCE`) i kategoryczna entropia krzyżowa (`CCE`).
- **optimizers** — implementuje algorytm *Stochastic gradient descent*.
- **mlp** — zamyka funckjonalność sieci w klasie `MLP`, przechowując listę warstw i implementując: propagację w przód, propagację wsteczną oraz kroki optymalizatora.
- **utils** — zawiera funkcje pomocnicze, w tym tworzenie mini batch'y, narzędzia do kodowania one-hot, metryki ewaluacyjne oraz ustawianie globalnego ziarna losowości.

Proces uczenia modelu sterowany jest przez metodę `MLP.fit()`, która w trakcie iteracji po kolejnych mini batchach i epokach na bieżąco zapisuje postępy uczenia. Wszystkie metadane zbierane są w formie słownika. Wśród jego kluczy znajdują się m.in. funkcje straty (w skali poszczególnych mini batchy oraz średnie na epokę dla zbioru treningowego i walidacyjnego) wprowadzone metryki (np. *Accuracy* dla klasyfikacji) oraz zmiany wartości kilku wybranych z góry wag sieci.

3 Eksperymenty — Zagadnienie regresji

3.1 Zbiory danych i metodyka badawcza

Badania przeprowadzono dla dwóch jednowymiarowych zbiorów regresyjnych. W obu przypadkach wejście stanowi pojedyncza cecha ciągła, a zakres zbioru uczącego wynosi $x \in [-2, 5]$; model przewiduje jedną wartość rzeczywistą $\hat{y}$.

- **Zbiór `data.activation`** opisuje nieliniową funkcję o kształcie sigmoidalnym/przejściowym. Wartości celu w obszarze uczącym mieszczą się w przybliżeniu w zakresie $[-265, -2]$.
- **Zbiór `data.cube`** zawiera zależność wielomianową trzeciego stopnia z szumem, a wartości celu w obszarze uczącym znajdują się w przybliżeniu w zakresie $[-198, 86]$.

Wykorzystano gotowe podziały na zbiory uczące i testowe, dostępne dla liczności $N \in \{100, 500, 1000, 10000\}$. Dane w eksperymentach pozostawiono w oryginalnej skali — nie zastosowano standaryzacji ani normalizacji. Jest to istotne, ponieważ duży zakres wartości celu wpływa na skalę gradientów i wrażliwość uczenia na współczynnik η. Warstwa wyjściowa składała się z jednego neuronu z aktywacją tożsamościową (bez dodatkowej nieliniowości), dzięki czemu model mógł przewidywać wartości z dowolnego zakresu. Domyślnie stosowano bias. Jakość mierzono przez MSE, MAE i współczynnik determinacji R^2. Wyniki R1–R4 raportowano jako średnią i odchylenie standardowe z 10 ziaren: $\{42, 123, 999, 0, 1, 7, 2024, 314, 2718, 31337\}$. Ziarno 42 wykorzystano jako reprezentatywne na wykresach pojedynczych trajektorii wag. We wszystkich uruchomieniach R1–R4 liczba rozbieżnych przebiegów wyniosła zero.

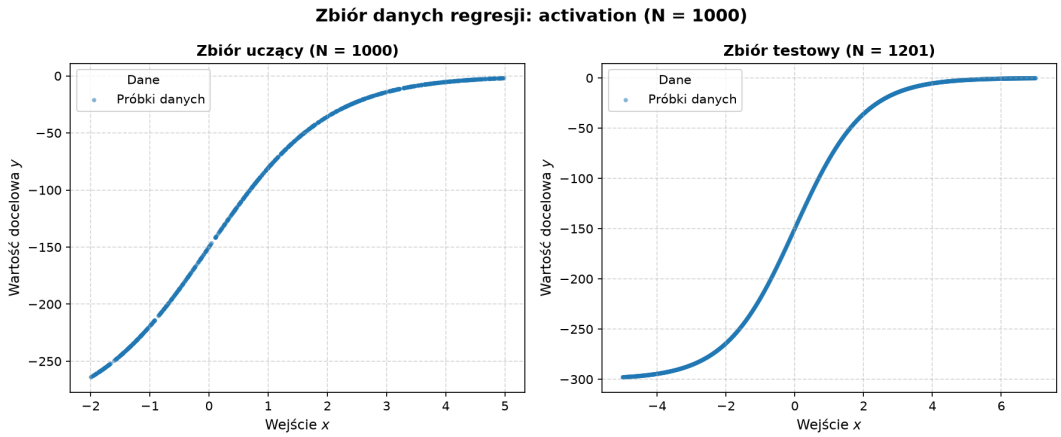
Liczbę epok dobierano osobno dla każdego eksperymentu i zbioru na podstawie plateau straty treningowej, a nie jakości na zbiorze testowym. Dla konfiguracji reprezentatywnych wykonywano kalibrację maksymalnie do 3000 epok na ziarnach 42, 123 i 999. Plateau określano jako względną poprawę straty mniejszą niż 1% w oknie 50 epok; medianę uzyskanych epok zaokrąglano w górę do wielokrotności 50. Przebiegi z niefinitywną stratą treningową pomijano przy wyznaczaniu mediany; jeśli strata pozostawała skończona, lecz plateau nie wystąpiło w limicie, do mediany włączano 3000 epok. Nie używano straty testowej do wyboru budżetu, ponieważ podział testowy, szczególnie dla `data.cube`, służy ocenie ekstrapolacji i musi pozostać niezależny od doboru hiperparametrów.

Kalibracja wskazała, że konfiguracje MAE w R3 osiągały plateau później niż pozostałe warianty (około 1260–1950 epok). Dlatego dla R3 zastosowano rozszerzony, wspólny budżet 1500 epok zamiast budżetu 100 epok wynikającego z mediany wszystkich konfiguracji. Dla niektórych przebiegów MAE na `data.activation` plateau może nadal nie wystąpić w tym limicie; budżet ustalono z góry, bez selekcji na podstawie wyników testowych.

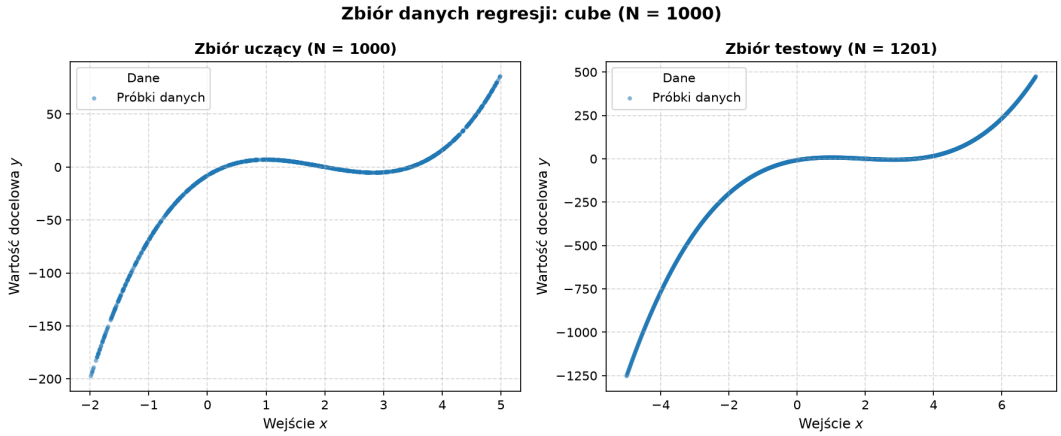
Tabela 1: Budżety epok zastosowane w eksperymentach regresyjnych.

Eksperyment	`data.activation`	`data.cube`
R1	100	100
R2	200	150
R3	1500	1500
R4	100	100

Na rysunkach krzywe modelu naniesiono na punkty odpowiednich podzbiorów. W eksperymentach architektonicznych i dotyczących funkcji straty podział testowy obejmuje zakresy poza przedziałem uczącym, dlatego ocenia nie tylko interpolację, lecz także ekstrapolację. Szczególnie wyraźnie widać to dla `data.cube`, którego wielomian rośnie gwałtownie poza obszarem danych uczących.



Rysunek 1: Zbiory uczący i testowy dla `data.activation` ($N = 1000$).



Rysunek 2: Zbiory uczący i testowy dla `data.cube` ($N = 1000$). Widoczny jest wzrost wartości funkcji poza zakresem uczącym.

3.2 Wpływ funkcji aktywacji w warstwach ukrytych

W eksperymencie R1 porównano funkcje `Sigmoid`, `Tanh` i `ReLU` w architekturze $[1, 32, 16, 1]$. Zastosowano 100 epok dla obu zbiorów (Tabela 1), zgodnie z kalibracją opisaną w metodyce, bez odwoływania się do straty testowej. W obu przypadkach stosowano mini batch o rozmiarze 32 i współczynnik uczenia $\eta = 0.001$. Dla `Sigmoid` i `Tanh` zastosowano inicjalizację Xavier, a dla `ReLU` — He.

Tabela 2: Wyniki eksperymentu R1 na zbiorze testowym: średnia ± odchylenie standardowe z 10 ziaren.

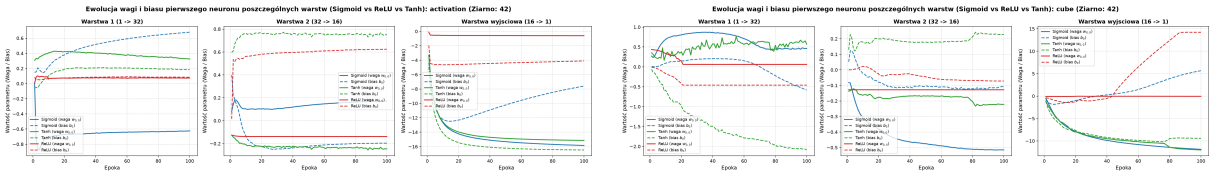
Zbiór	Aktywacja	MSE	MAE	R^2
`activation`	Sigmoid	225.34 ± 2.89	8.89 ± 0.21	0.9844 ± 0.0002
	Tanh	231.60 ± 11.84	7.73 ± 0.15	0.9840 ± 0.0008
	ReLU	2208.62 ± 4427.49	22.86 ± 29.06	0.8471 ± 0.3065
`cube`	Sigmoid	86674.14 ± 400.46	156.91 ± 1.16	0.2846 ± 0.0033
	Tanh	84383.75 ± 2434.43	147.19 ± 3.28	0.3035 ± 0.0201
	ReLU	28507.46 ± 3704.76	91.03 ± 10.36	0.7647 ± 0.0306

Na `data.activation` warianty `Sigmoid` i `Tanh` uzyskały zbliżony testowy MSE (odpowiednio

225.34 i 231.60), przy czym `Tanh` osiągnął nieco niższe MAE. `ReLU` wypadła słabiej i wykazała dużą zmienność między ziarnami (odchylenie MSE 4427.49), choć żaden przebieg nie został oznaczony jako rozbieżny. Krzywa `ReLU` jest odcinkami liniowa, natomiast `Sigmoid` i `Tanh` dają gładkie przejście. Różnice są szczególnie widoczne poza zakresem uczącym: aktywacje gładkie zbliżają się do stałych wartości, a `ReLU` kontynuuje ekstrapolację liniową.

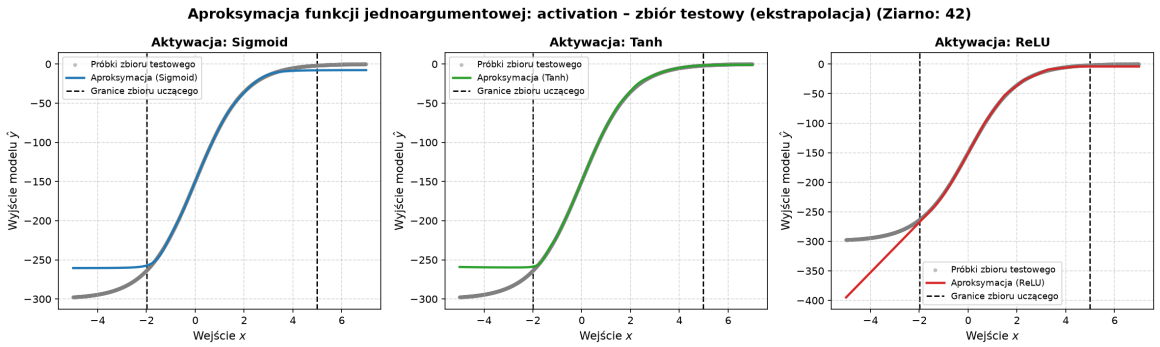
Na `data.cube` najniższy testowy MSE uzyskała `ReLU` (28507.46 ± 3704.76), wyraźnie lepiej niż `Sigmoid` i `Tanh`. Mimo poprawy, błąd pozostaje wysoki, ponieważ podział testowy wymaga ekstrapolacji szybko rosnącego wielomianu. Aktywacje `Sigmoid` i `Tanh` spłaszczają predykcję poza zakresem uczącym, podczas gdy `ReLU` może kontynuować ekstrapolację liniową. Wniosek ten dotyczy skalibrowanego budżetu 100 epok i badanych konfiguracji.

Rysunek 3 przedstawia przebieg wagi $w_{0,0}$ (linia ciągła) i biasu b_0 (linia przerywana) pierwszego neuronu w każdej warstwie dla reprezentatywnego ziarna 42.

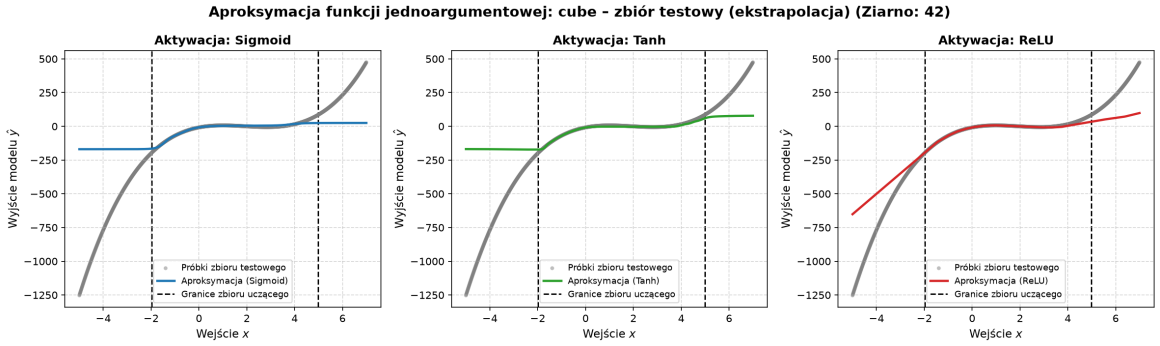


(a) `data.activation` (100 epok). (b) `data.cube` (100 epok).

Rysunek 3: Ewolucja wagi wejściowej i biasu pierwszego neuronu w kolejnych warstwach sieci R1 dla funkcji aktywacji Sigmoid, Tanh i ReLU (ziarno 42).



Rysunek 4: Aproksymacja `data.activation` na zbiorze testowym dla trzech funkcji aktywacji. Linie przerywane wyznaczają zakres uczący; poza nim widoczne są odmienne zachowania ekstrapolacyjne.



Rysunek 5: Aproksymacja `data.cube` na zbiorze testowym dla trzech funkcji aktywacji. Żadna z krzywych nie odtwarza dobrze wzrostu wielomianu poza zakresem uczącym.

3.3 Wpływ architektury sieci: głębokość i szerokość

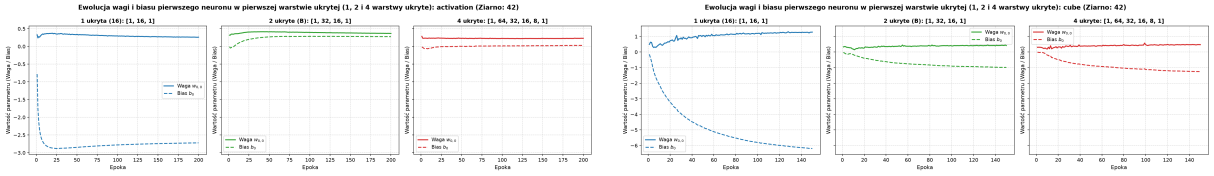
W eksperymencie R2 sprawdzono osiem architektur: model bez warstwy ukrytej $[1, 1]$, sieci z jedną warstwą o szerokości 4, 16 lub 64 neuronów, dwie wariacje z dwiema warstwami oraz sieci z trzema i czterema warstwami ukrytymi. Pozostałe warunki ustalono: aktywacja ukryta `Tanh`, inicjalizacja Xavier, MSE, mini batch 32 i $\eta = 0.0005$. Zastosowano 200 epok dla `data.activation` i 150 dla `data.cube` (Tabela 1). Poniższe wartości są podsumowaniem 10 ziaren.

Tabela 3: Testowy MSE (średnia ± odchylenie standardowe) i średnie R^2 w zależności od architektury (R2, 10 ziaren, $N = 1000$).

	`data.activation`		`data.cube`	
Architektura	**MSE**	R^2	**MSE**	R^2
$[1, 1]$ (0 ukrytych)	2349.42 ± 8.59	0.8374 ± 0.0006	94845.96 ± 30.34	0.2172 ± 0.0003
$[1, 4, 1]$	549.03 ± 40.53	0.9620 ± 0.0028	92786.17 ± 322.89	0.2342 ± 0.0027
$[1, 16, 1]$	207.90 ± 6.87	0.9856 ± 0.0005	80766.36 ± 208.14	0.3334 ± 0.0017
$[1, 64, 1]$	79.91 ± 3.41	0.9945 ± 0.0002	75373.49 ± 562.81	0.3779 ± 0.0046
$[1, 16, 8, 1]$	298.79 ± 8.42	0.9793 ± 0.0006	87369.75 ± 278.37	0.2789 ± 0.0023
$[1, 32, 16, 1]$	221.67 ± 1.68	0.9847 ± 0.0001	83028.12 ± 505.06	0.3147 ± 0.0042
$[1, 32, 16, 8, 1]$	313.06 ± 22.23	0.9783 ± 0.0015	87632.64 ± 430.73	0.2767 ± 0.0036
$[1, 64, 32, 16, 8, 1]$	306.60 ± 8.29	0.9788 ± 0.0006	87805.53 ± 214.87	0.2753 ± 0.0018

Wśród zbadanych architektur najlepszy wynik na obu zbiorach uzyskał szeroki model jednowarstwowy $[1, 64, 1]$: testowy MSE wyniósł 79.91 ± 3.41 dla `data.activation` i 75373.49 ± 562.81 dla `data.cube`. Zwiększenie szerokości warstwy z 4 do 64 neuronów poprawiało wynik, natomiast dodanie kolejnych warstw nie przewyższyło modelu $[1, 64, 1]$. Błędy dla `cube` pozostają wysokie z uwagi na ekstrapolację.

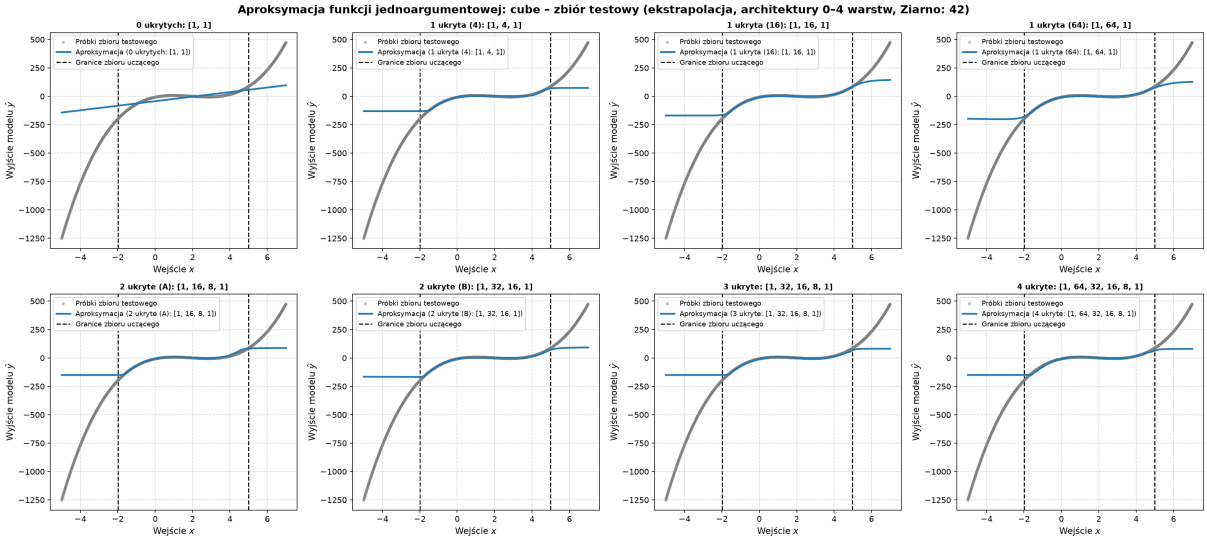
Na Rysunku 6 pokazano zmianę $w_{0,0}$ i b_0 pierwszego neuronu warstwy ukrytej dla sieci z jedną, dwiema i czterema warstwami ukrytymi. Krzywe dotyczą ziarna 42; porównanie parametrów ma charakter ilustracyjny, ponieważ neuron o tym samym indeksie w różnych architekturach nie musi pełnić tej samej funkcji.



(a) `data.activation`. (b) `data.cube`.

Rysunek 6: Ewolucja wagi $w_{0,0}$ i biasu b_0 pierwszego neuronu pierwszej warstwy ukrytej dla architektur o różnej głębokości w eksperymencie R2 (ziarno 42; 200 epok dla `data.activation` i 150 dla `data.cube`).

Wartości treningowe były znacznie niższe od testowych, szczególnie dla `data.cube`. Rozbieżność ta jest zgodna z faktem, że test ocenia ekstrapolację, a nie wyłącznie interpolację. Nie należy jej zatem interpretować wyłącznie jako klasycznego przeuczenia do punktów treningowych. Przykładowe krzywe predykcji dla wszystkich architektur na zbiorze testowym przedstawia Rysunek 7.



Rysunek 7: Wpływ głębokości i szerokości sieci na ekstrapolację `data.cube` (reprezentatywne ziarno 42).

3.4 Wpływ miary błędu (funkcji straty)

W eksperymencie R3 porównano minimalizację MSE i MAE w tej samej architekturze $[1, 32, 16, 1]$ z aktywacją `Tanh`. Ponieważ MAE ma gradient o w przybliżeniu stałym module, a gradient MSE zależy od wielkości reszty, dla obu funkcji sprawdzono trzy współczynniki uczenia (0.001, 0.005 i 0.01). Zastosowano 1500 epok dla obu zbiorów i wszystkich konfiguracji (Tabela 1), aby dać wolniej zbieżnym wariantom MAE dłuższy czas uczenia niż w pierwotnym przebiegu 100-epokowym. Końcowe MSE i MAE obliczano tak samo niezależnie od optymalizowanej funkcji straty.

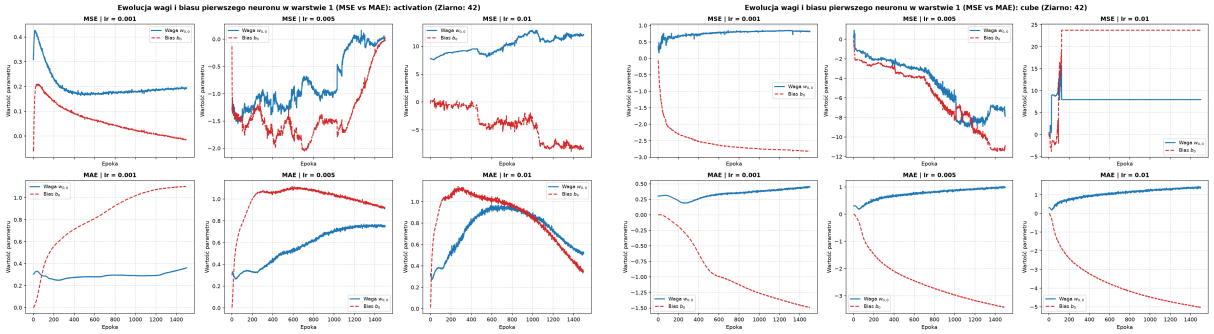
Tabela 4: Testowe MSE i MAE (średnia ± odchylenie standardowe z 10 ziaren) dla wszystkich konfiguracji R3.

Zbiór	Strata	η	Testowy MSE	Testowy MAE
`activation`	MSE	0.001	167.99 ± 28.18	6.08 ± 0.44
`activation`	MSE	0.005	2032.87 ± 2656.11	21.08 ± 12.85
`activation`	MSE	0.010	2022.53 ± 1834.26	27.37 ± 14.47
`activation`	MAE	0.001	756.68 ± 26.05	14.95 ± 0.59
`activation`	MAE	0.005	612.99 ± 109.31	12.09 ± 0.97
`activation`	MAE	0.010	244.94 ± 35.49	8.62 ± 0.66
`cube`	MSE	0.001	77184.53 ± 3384.97	134.88 ± 3.87
`cube`	MSE	0.005	86198.41 ± 6053.99	161.96 ± 6.10
`cube`	MSE	0.010	84032.24 ± 13205.54	164.95 ± 18.75
`cube`	MAE	0.001	95539.71 ± 502.19	157.46 ± 1.05
`cube`	MAE	0.005	79295.36 ± 292.17	138.61 ± 0.69
`cube`	MAE	0.010	78240.59 ± 602.90	138.58 ± 1.06

Po 1500 epokach najniższy testowy MSE na obu zbiorach uzyskała konfiguracja MSE z $\eta = 0.001$: 167.99 ± 28.18 dla `data.activation` oraz 77184.53 ± 3384.97 dla `data.cube`. Najlepszy wariant MAE używał $\eta = 0.01$ i uzyskał odpowiednio 244.94 ± 35.49 oraz 78240.59 ± 602.90, czyli był już znacznie bliżej MSE niż w pierwotnym przebiegu 100-epokowym. Nadal jednak nie przewyższył go pod względem testowego MSE. Wysokie błędy `cube` przypominają, że podział testowy obejmuje ekstrapolację.

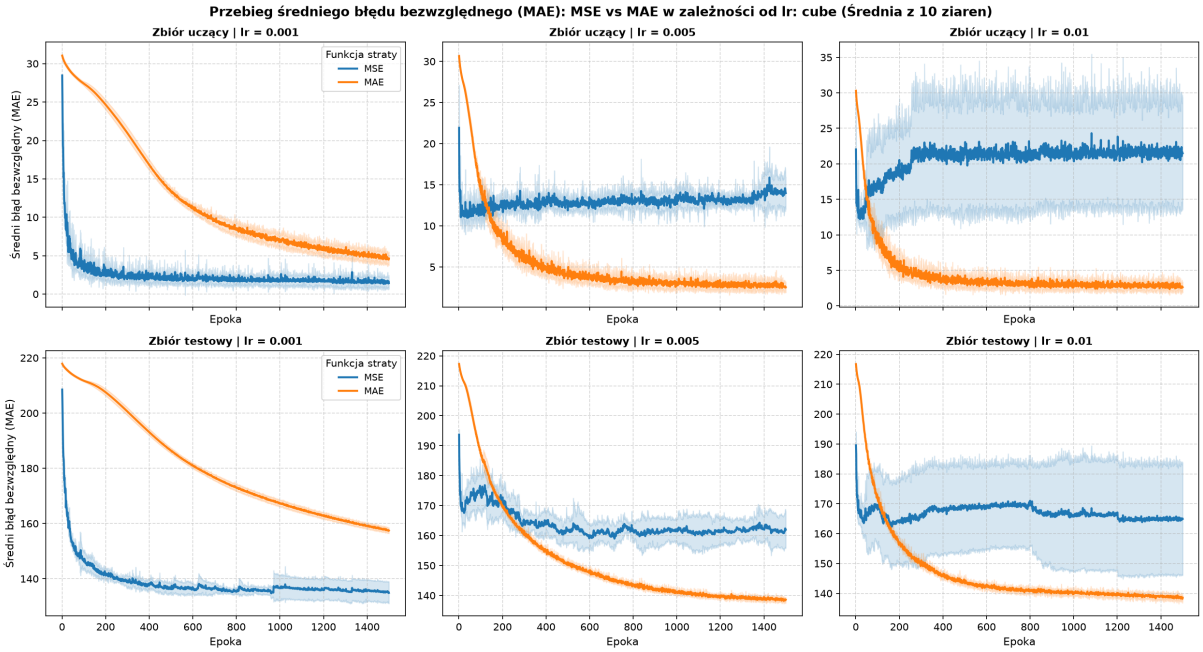
Krzywe uczenia pokazują, że porównanie zależy od kroku uczenia: dla MAE zwiększenie η poprawiało uzyskane wyniki, natomiast dla MSE najlepszy był mały krok 0.001. Większe kroki MSE dawały wyższe błędy i dużą zmienność między ziarnami, szczególnie na `data.cube`. Wydłużenie treningu znacznie poprawiło wyniki MAE; mimo to 1500 epok może nie wystarczyć do osiągnięcia plateau w każdym wariancie MAE dla `data.activation`, zgodnie z wcześniejszą kalibracją. W otoczeniu minimum stały moduł gradientu MAE może utrudniać dokładne ustalenie parametrów i prowadzić do oscylacji; MSE daje coraz mniejsze korekty wraz ze zmniejszaniem reszty. Wyniki dotyczą wyłącznie badanych konfiguracji i nie oznaczają, że MAE jest ogólnie gorszą miarą — funkcję straty i tempo uczenia należy dobierać wspólnie.

Rysunek 8 pokazuje ewolucję wagi $w_{0,0}$ i biasu b_0 pierwszego neuronu w pierwszej warstwie ukrytej. Osobne panele odpowiadają optymalizowanej stracie i wartości współczynnika uczenia; przedstawiono reprezentatywne ziarno 42.



(a) `data.activation`. (b) `data.cube`.

Rysunek 8: Trajektorie wagi $w_{0,0}$ i biasu b_0 podczas optymalizacji MSE i MAE dla trzech wartości współczynnika uczenia (R3, ziarno 42, 1500 epok).



Rysunek 9: Przebieg MAE na zbiorach uczącym i testowym dla optymalizacji MSE oraz MAE na `data.cube`, przy trzech wartościach współczynnika uczenia.

3.5 Wpływ rozmiaru zbioru danych (opcjonalnie)

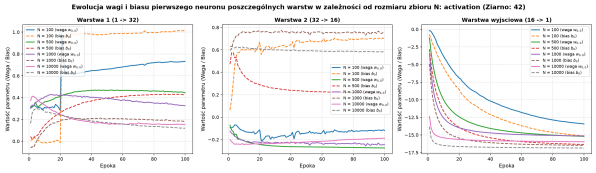
W eksperymencie R4 zbadano wpływ liczności zbioru uczącego $N \in \{100, 500, 1000, 10000\}$. Dla każdej liczności użyto architektury $[1, 32, 16, 1]$, aktywacji `Tanh`, inicjalizacji Xavier, straty MSE i $\eta = 0.001$. Zastosowano 100 epok dla obu zbiorów (Tabela 1); wyniki podsumowują 10 ziaren.

Tabela 5: Testowy MSE w zależności od liczności zbioru uczącego (średnia ± odchylenie standardowe z 10 ziaren).

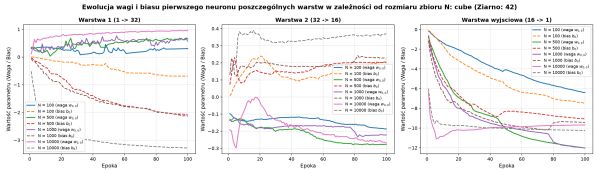
N	`data.activation`	`data.cube`
100	1460.92 ± 899.65	102338.29 ± 2780.48
500	295.70 ± 21.98	86078.31 ± 1801.05
1000	231.60 ± 11.84	84383.75 ± 2434.43
10000	150.61 ± 18.65	77124.69 ± 2493.34

Przy skalibrowanym budżecie 100 epok testowy MSE malał wraz ze wzrostem N dla obu zbiorów. Dla `data.activation` obniżył się z 1460.92 przy $N = 100$ do 150.61 przy $N = 10000$; najmniejsza próbka miała również dużą zmienność między ziarnami (899.65). Dla `data.cube` MSE spadł z 102338.29 do 77124.69, choć błąd nadal pozostawał wysoki ze względu na ekstrapolację. W tych wynikach większa liczność próbki poprawiała generalizację; nie zaobserwowano wcześniejszego wzrostu błędu dla $N = 10000$.

Wykresy wagi $w_{0,0}$ i biasu b_0 w R4 (Rysunek 10) pokazują ich przebieg dla poszczególnych liczności zbioru uczącego. Są to parametry pierwszego neuronu każdej kolejnej warstwy dla reprezentatywnego ziarna 42.

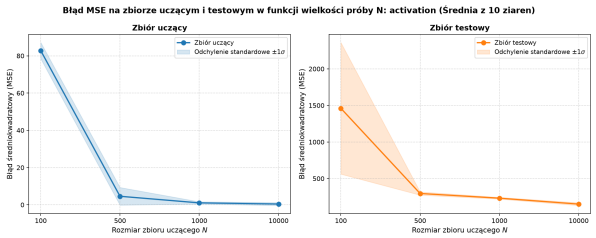


(a) `data.activation`.

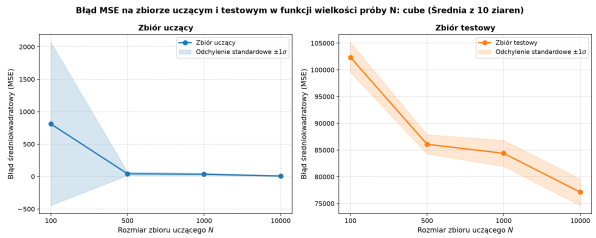


(b) `data.cube`.

Rysunek 10: Ewolucja wagi $w_{0,0}$ i biasu b_0 w kolejnych warstwach sieci R4 dla różnych liczności zbioru treningowego (ziarno 42, 100 epok).



(a) `data.activation`



(b) `data.cube`

Rysunek 11: Błąd MSE na zbiorach uczących i testowych w zależności od liczności próby N. Wstęgi przedstawiają odchylenie standardowe dla 10 ziaren.

3.6 Podsumowanie i wnioski z części regresyjnej

Przeprowadzone eksperymenty pokazują, że wynik regresji MLP zależy łącznie od charakteru aproksymowanej funkcji, funkcji aktywacji, szerokości sieci, liczby próbek oraz współczynnika uczenia.

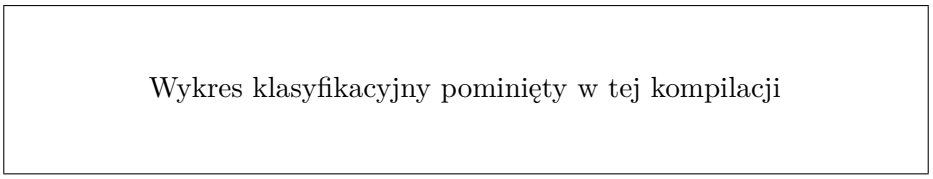
- Dla `activation` funkcje `Sigmoid` i `Tanh` dawały zbliżone wyniki w R1, a w R2 poszerzenie pojedynczej warstwy z 4 do 64 neuronów wyraźnie obniżało błąd. W badanych ustawieniach dodawanie kolejnych warstw nie przewyższyło szerokiej sieci jednowarstwowej.
- Dla wielomianowego `cube` dobre dopasowanie w obszarze uczącym nie przełożyło się na ekstrapolację. Modele zwracały znacznie zaniżone predykcje poza przedziałem treningowym, co skutkowało wysokim błędem testowym i niskim R^2. Jest to ograniczenie testowanych modeli i konfiguracji, nie zaś dowód, że sieć MLP nie może aproksymować wielomianu w obszarze interpolacji.
- W R1 dla `cube` najniższy błąd uzyskała `ReLU`, natomiast dla `activation` najlepsze wyniki dawały gładkie funkcje. W R3 MSE z $\eta = 0.001$ przewyższało wszystkie przetestowane warianty MAE pod względem testowego MSE; wybór funkcji straty należy jednak rozpatrywać łącznie z krokiem uczenia.
- W R4 większa liczność próbki poprawiała wyniki testowe dla obu zbiorów w zastosowanym budżecie 100 epok. Budżety epok kalibrowano na podstawie plateau straty treningowej, bez wykorzystania zbioru testowego; wpływ ich zastosowania na generalizację oceniano dopiero po zakończeniu treningu.
- Dane wykorzystano w surowej skali, zgodnie z implementacją eksperymentów. Standaryzacja cech i celów — wyznaczana na zbiorze uczącym i stosowana następnie do testowego — mogłaby ułatwić dobór współczynnika uczenia. Nie zmieniłaby jednak faktu, że zachowanie modelu daleko poza zakresem obserwacji wymaga osobnej oceny.

4 Eksperymenty — Zagadnienie klasyfikacji

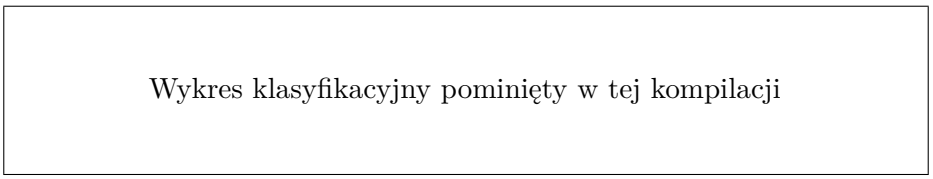
4.1 Zbiory danych

W tej części projektu, badano wykorzystanie modelu `MLP` do klasyfikacji punktów w przestzeni $\mathbb{R}^2$. Do zadania dostarczono dwa zbiory danych, każdy w kilku wersjach różniących się wielkością. Aby uwypuklić różnice między różnymi architekturami, skupiono się na rozmiarze $N = 100$.

- **Zbiór `data.simple`** — klasyfikacja binarnej (2 klasy). Skupiska klas rozdzielone są łagodną, ale nieliniową granicą (Rysunek 12). W warstwie wyjściowej stosowano przeważnie pojedynczy neuron z funkcją aktywacji `Sigmoid` oraz binarną entropię krzyżową (`BinaryCrossEntropyLoss`). Wyjątkiem jest eksperyment 3 którego celem było porównanie entropii krzyżowej do błędu średniokwadratowego (`MSE`).
- **Zbiór `data.three_gauss`** — klasyfikacja wieloklasowa (3 klasy). Skupiska powstały przez nałożenie na siebie dwuwymiarowych rozkładów gaussowskich (Rysunek 13). Kluczową cechą tego zbioru jest wyraźne nakładanie się rozkładów klas na środku przestrzeni. Ze względu na to przenikanie się klas, zbiór jest trudniejszy w klasyfikacji przez co idealne rozpoznawanie klas nie jest możliwe bez przeuczenia. Na wyjściu sieci stosowano 3 neurony z aktywacją `Softmax`, etykiety kodowane w postaci one-hot oraz funkcję kategorycznej entropii krzyżowej (`CategoricalCrossEntropyLoss`). Wyjątkiem ponownie był eksperyment 3 w którym porównano entropię krzyżową z `MSE`.



Rysunek 12: Wizualizacja zbioru uczącego i testowego dla problemu binarnego `data.simple` ($N = 100$).



Rysunek 13: Zbiór uczący i testowy dla problemu wieloklasowego `data.three_gauss` ($N = 100$ na klasę). Widoczne nakładanie się klas w centrum przestrzeni.

4.2 Eksperyment 1 - Funkcje aktywacji w warstwach ukrytych

W ramach eksperymentu zbadano wpływ doboru funkcji aktywacji w warstwach ukrytych (`Sigmoid`, `Tanh`, `ReLU`) na przebieg uczenia, stabilność wag oraz finalny przebieg granic decyzyjnych. Eksperymenty przeprowadzono na jednej architekturze $[2, 32, 16, C]$ ($C = 1$ dla klasyfikacji binarnej, $C = 3$ dla wieloklasowej) przy użyciu optymalizatora `SGD` ($\eta = 0.05$, 150 epok) dla 3 różnych ziaren losowości $(42, 123, 999)$.

Podsumowanie uzyskanych dokładności (*accuracy*) predykcji na zbiorze uczącym i testowym przedstawiono w Tabeli 6.

Tabela 6: Dokładność klasyfikacji dla modeli finalnych w zależności od funkcji aktywacji (średnia ± odchylenie standardowe z 3 ziaren).

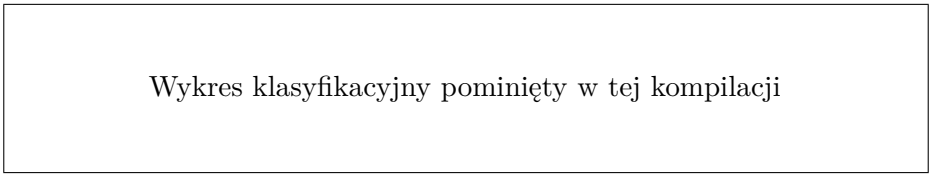
Zbiór danych	**Funkcja aktywacji**	**Zbiór testowy [%]**	**Zbiór uczący [%]**
`data.simple`	Sigmoid	97.33 ± 1.25	96.67 ± 2.49
	Tanh	$\mathbf{99.67} \pm 0.47$	100.00 ± 0.00
	ReLU	$\mathbf{99.67} \pm 0.47$	100.00 ± 0.00
`data.three_gauss`	Sigmoid	93.11 ± 0.16	92.44 ± 0.16
	Tanh	992.8 ± 0.16	92.56 ± 0.16
	ReLU	$\mathbf{93.22} \pm 0.16$	94.11 ± 0.16

4.2.1 Zbiór danych simple

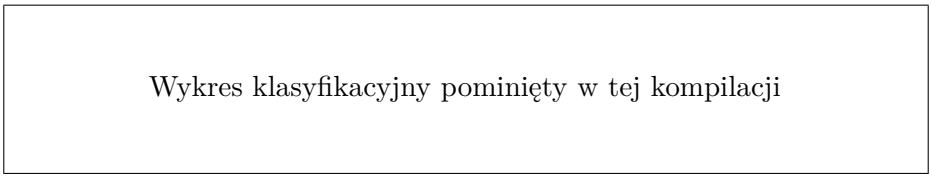
W zadaniu binarnym modele z aktywacją `Tanh` oraz `ReLU` zdołały w 100% nauczyć się rozpoznawać klasy na zbiorach treningowych i dobrze generalizują to na zbiorze testowym (99.67%). Funkcja `Sigmoid` zbiegała wyraźnie wolniej ze względu na nasycenie gradientu (stosunkowo mała wartość pochodnej funkcji sigma). Poniżej przedstawiono wykresy ilustrujące przebieg uczenia i finalne rezultaty na zbiorze prostym.

Na Rysunku 14 można zaobserwować, że dokładność sieci z aktywacją `Sigmoid` znacznie wolniej zbiega do 1. Dodatkowo trajektoria krzywej jest bardziej chaotyczna i wykazuje większe odchylenie standardowe (na badanej próbce 3 ziaren losowych), co sugeruje, że aktywacja `Sigmoid` jest bardziej wrażliwa na losową inicjalizację wag. Gdy porównać nasycenie kolorów na Rysunku 15, widać, że granice decyzyjne dla funkcji `ReLU` i `Tanh` są jasno zdefiniowane, co oznacza, że model

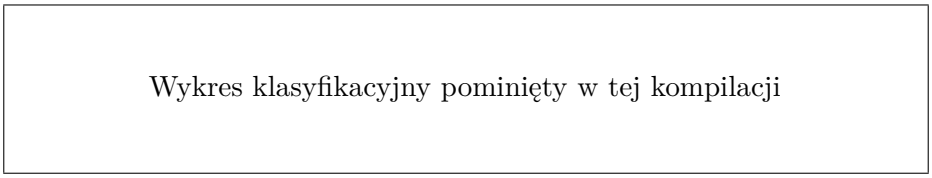
jest pewny swoich decyzji. W przypadku `Sigmoid` sytuacja jest odwrotna — występuje szerokie pasmo wysokiej niepewności (szacowane prawdopodobieństwo bliskie 0.5). Przebieg funkcji straty (Rysunek 16) pokazuje gwałtowny spadek błędu treningowego dla `ReLU` i `Tanh` już w pierwszych 20 epokach, podczas gdy strata w modelu `Sigmoid` maleje powoli i jednostajnie przez cały trening. Zmiany pierwszej wagi $w_{0,0}$ oraz biasu b_0 pierwszego neuronu (Rysunek 17) są stabilne i nie ma w nich oscylacji.



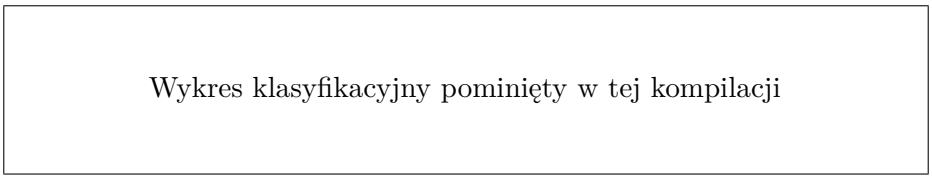
Rysunek 14: Przebieg dokładności klasyfikacji w kolejnych epokach dla zbioru `data.simple` (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 15: Granice decyzyjne w przestrzeni $\mathbb{R}^2$ dla zbioru `data.simple` w zależności od funkcji aktywacji.



Rysunek 16: Przebieg funkcji straty w kolejnych epokach dla zbioru `data.simple` (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



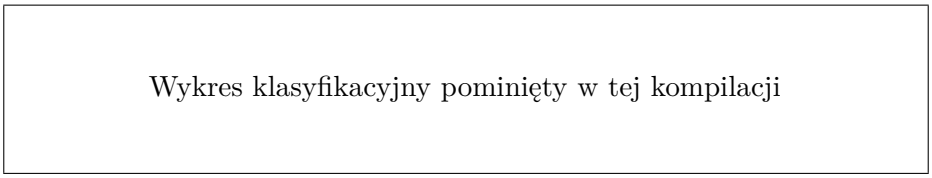
Rysunek 17: Ewolucja wagi $w_{0,0}$ i biasu b_0 pierwszego neuronu poszczególnych warstw dla zbioru `data.simple` (ziarno 42).

4.2.2 Zbiór danych three_gauss

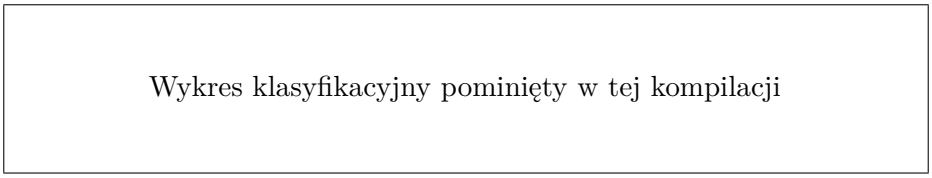
W zbiorze wieloklasowym wszystkie badane funkcje aktywacji osiągnęły zbliżoną dokładność na poziomie 92.9–93.2%. Ograniczenie to wynika z fizycznego nakładania się na siebie rozkładów trzech klas.

Na Rysunku 18 przedstawiono finalne granice decyzyjne w przestrzeni $\mathbb{R}^2$. Funkcja `ReLU` tworzy odcinkowo liniowe krawędzie podziału, podczas gdy `Tanh` i `Sigmoid` wyznaczają gładkie krzywe. We wszystkich modelach widoczne są punkty błędnie zaklasyfikowane w centralnej strefie nakładania się klas. Krzywe dokładności na Rysunku 19 pokazują, że `ReLU` i `Tanh` już

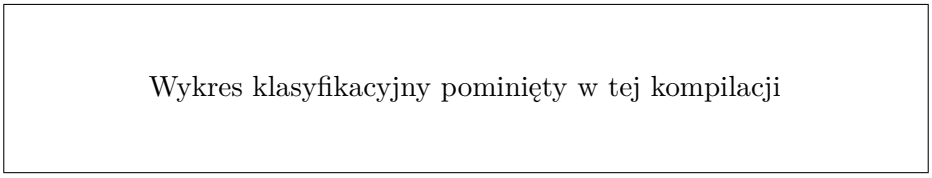
w kilkunastu epokach osiągają dokładność ok. 93%, podczas gdy `Sigmoid` początkowo mocno oscyluje i potrzebuje ponad 80 epok na ustabilizowanie predykcji. Pozostałe wykresy obrazują podobne zjawiska jak w przypadku zbioru `data.simple`.



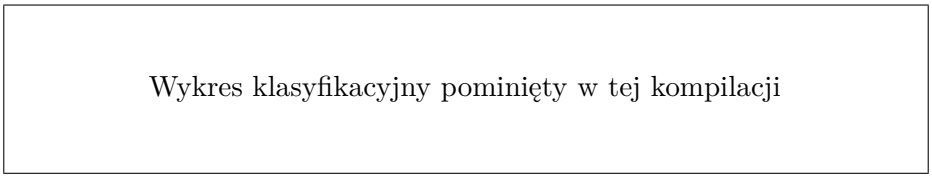
Rysunek 18: Granice decyzyjne w przestrzeni $\mathbb{R}^2$ dla zbioru `data.three_gauss` w zależności od funkcji aktywacji.



Rysunek 19: Przebieg dokładności klasyfikacji w kolejnych epokach dla zbioru `data.three_gauss` (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 20: Przebieg funkcji straty w kolejnych epokach dla zbioru `data.three_gauss` (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 21: Ewolucja wagi $w_{0,0}$ i biasu b_0 pierwszego neuronu poszczególnych warstw dla zbioru `data.three_gauss` (ziarno 42).

Wnioski. Podsumowując wyniki:

- Funkcje aktywacji `Tanh` oraz `ReLU` zapewniają znacznie szybszą redukcję błędu i wyższą odporność na losową inicjalizację parametrów niż funkcja `Sigmoid`, która cierpi na spowolnienie uczenia wywołane nasyceniem gradientu.
- Kształt wyznaczonych granic decyzyjnych odzwierciedla charakter funkcji aktywacji (odcinkowo liniowe dla `ReLU` vs gładkie dla `Tanh`). W zbiorze `data.three_gauss` w którym klasy się nakładają wszystkie modele osiągają zbliżoną skuteczność ograniczoną górną granicą ok. 93%.

4.3 Eksperyment 2 - Architektura sieci

W ramach eksperymentu zbadano przebieg uczenia i finalne wyniki sieci w zależności od jej głębokości (od 0 do 4 warstw ukrytych) oraz wielkości poszczególnych warstw. Przetestowano 8 wariantów (gdzie C oznacza liczbę rozpoznawanych klas):

- model liniowy bez warstw ukrytych $[2, C]$
- trzy modele z 1 warstwą ukrytą ($[2, 4, C]$, $[2, 16, C]$, $[2, 64, C]$)
- dwa modele 2 warstwowe ($[2, 16, 8, C]$, $[2, 32, 16, C]$)
- sieć 3 warstwową $[2, 32, 16, 8, C]$
- sieć 4 warstwową $[2, 64, 32, 16, 8, C]$

Na podstawie wyników eskperymentu 1, tym razem zastosowano wszędzie funkcję aktywacji `ReLU` w warstwach ukrytych. Ziarna losowości pozostają bez zmian $(42, 123, 999)$. Natomiast hiperparametry uczenia zostały lekko zmodyfikowane ($\eta = 0.01$, 250 epok) aby głębsze sieci miały szansę zostać dotrenowane.

4.3.1 Zbiór danych simple

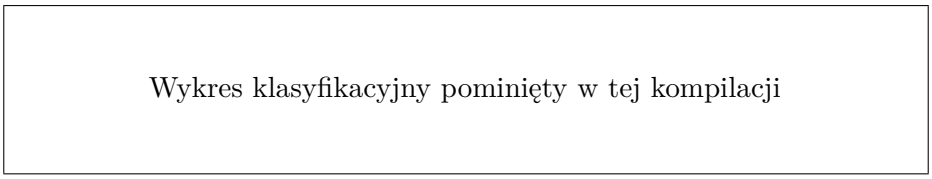
Wyniki dokładności klasyfikacji dla badanych architektur na zbiorze `data.simple` przedstawiono w Tabeli 7.

Tabela 7: Dokładność klasyfikacji w zależności od architektury dla zbioru `data.simple` (średnia $\pm$ odchylenie standardowe z 3 ziaren).

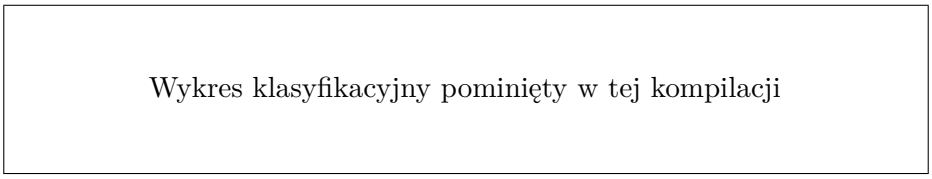
Architektura	**Warstwy ukryte**	**Zbiór testowy [%]**	**Zbiór uczący [%]**
0 ukrytych: [2]	0	95.33 ± 1.25	94.00 ± 0.82
1 ukryta (4): [2, 4]	1	92.00 ± 3.27	90.00 ± 2.16
1 ukryta (16): [2, 16]	1	98.67 ± 1.25	96.67 ± 0.94
1 ukryta (64): [2, 64]	1	98.33 ± 0.94	99.33 ± 0.47
2 ukryte (A): [2, 16, 8]	2	98.33 ± 0.94	99.33 ± 0.47
2 ukryte (B): [2, 32, 16]	2	$\mathbf{99.33 \pm 0.47}$	100.00 ± 0.00
3 ukryte: [2, 32, 16, 8]	3	98.67 ± 1.25	99.67 ± 0.47
4 ukryte: [2, 64, 32, 16, 8]	4	98.67 ± 0.47	100.00 ± 0.00

Na Rysunku 22 przedstawiono zmiany granic decyzyjnych wraz ze wzrostem złożoności sieci. Model liniowy (zero warstw ukrytych) wyznacza liniową granicę, która nie jest w stanie dokładnie odwzorować zakrzywionego kształtu klas podczas gdy dodanie jednej ukrytej warstwy 16 neuronów pozwala na płynne dopasowanie granicy i znacznie lepsze podzielenie przestrzeni. Głębsze architektury oferują bardziej pewne predykcje i bardziej szczegółową krzywą rozdzielającą przestrzeń.

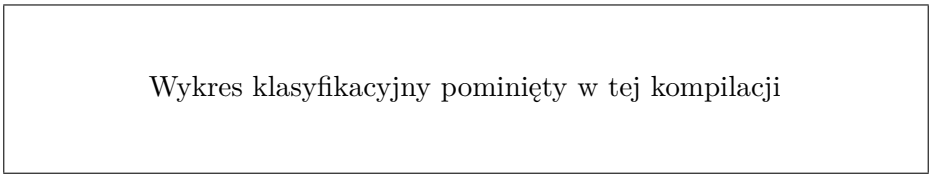
Krzywe dokładności wraz z postępami w uczeniu (Rysunek 23) pokazują, że sieci głębsze (2-4 warstwy) osiągają zbieżność znacznie szybciej i mają mniejsze odchylenie standardowe. Wąska sieć $[2, 4]$ uczy się z kolei bardzo wolno, z szerokim przedziałem niepewności co sugeruje że jest wrażliwa na inicjalizajcę wag. Podobnie w przypadku funkcji straty, (Rysunek 24) sieci płytkie uczą się wolniej (w szcególności model liniowy przy 250 epokach zatrzymuje się na poziomie ok. 0.38), a dodawanie kolejnych warstw z reguły sprawia że sieć szybciej zmniejsza swój błąd uczenia. Największa przetestowana sieć 4 warstwowa osiąga wartość straty na poziomie 0.05.



Rysunek 22: Kształt granic decyzyjnych w przestrzeni cech $\mathbb{R}^2$ dla zbioru `data.simple` w zależności od architektury sieci.



Rysunek 23: Przebieg dokładności klasyfikacji w kolejnych epokach dla zbioru `data.simple` w zależności od architektury (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 24: Przebieg funkcji straty w kolejnych epokach dla zbioru `data.simple` w zależności od architektury (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).

4.3.2 Zbiór danych three_gauss

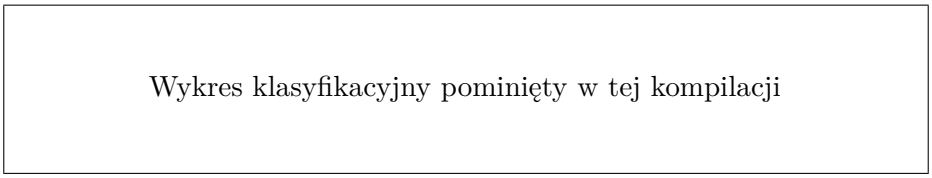
Wyniki dokładności klasyfikacji w zbiorze wieloklasowym `data.three_gauss` zestawiono w Tabeli 8. Tak jak w eksperymencie 1, można zaobserwować że żaden z modeli nie przekroczył granicy ok. 93.0% z uwagi na nakładające się klasy. Natomiast modele głębsze radziły sobie odrobinę lepiej. Ciekawe jest to, że liniowy model bez żadnych warstw ukrytych osiąga podobny wynik do pozostałych sieci. Wskazuje to na to, że zbiór jest dość łatwy do rozdzielenia w sposób liniowy, a nauczenie się szumu wynikającego z nakładania się klas nie pozwala głębszym modelom osiągnąć znacząco lepszych wyników.

Tabela 8: Dokładność klasyfikacji w zależności od architektury dla zbioru `data.three_gauss` (średnia $\pm$ odchylenie standardowe z 3 ziaren).

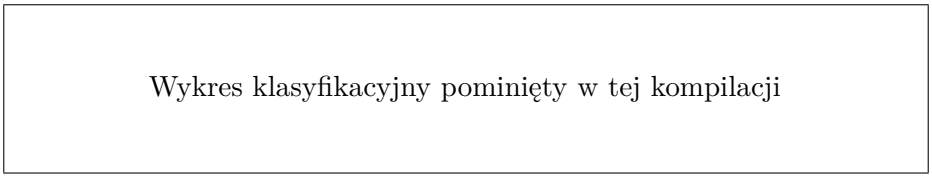
Architektura	**Warstwy ukryte**	**Zbiór testowy [%]**	**Zbiór uczący [%]**
0 ukrytych: [2]	0	92.78 ± 0.16	92.00 ± 0.47
1 ukryta (4): [2, 4]	1	92.44 ± 0.87	91.33 ± 0.54
1 ukryta (16): [2, 16]	1	92.67 ± 0.27	91.78 ± 0.16
1 ukryta (64): [2, 64]	1	92.89 ± 0.16	92.67 ± 0.27
2 ukryte (A): [2, 16, 8]	2	92.78 ± 0.16	92.33 ± 0.00
2 ukryte (B): [2, 32, 16]	2	$\mathbf{93.44 \pm 0.16}$	93.22 ± 0.63
3 ukryte: [2, 32, 16, 8]	3	$\mathbf{93.44 \pm 0.16}$	93.67 ± 0.27
4 ukryte: [2, 64, 32, 16, 8]	4	$\mathbf{93.44 \pm 0.16}$	94.33 ± 0.00

Na Rysunku 25 zobrazowano granice decyzyjne wyznaczone przez badane architektury. Model liniowy, podobnie jak wcześniej dzieli przestrzeń prostymi, podczas gdy architektury głębsze

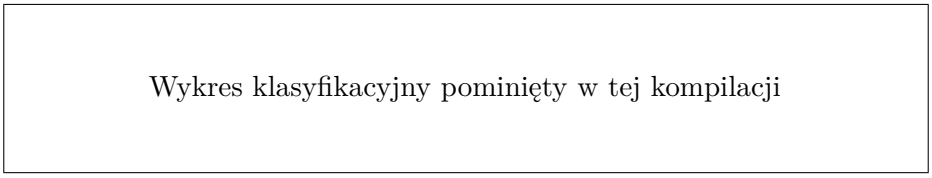
tworzą dokładniejsze granice klasyfikacji. We wszystkich przypadkach jednak w centrum obrazka widoczne są punkty błędnie zaklasyfikowane z uwagi na nakładanie się rozkładów. Pozostałe wykresy prezentują się bardzo podobnie do tych ze zbioru `data.simple`, wnioski są analogiczne.



Rysunek 25: Kształt granic decyzyjnych w przestrzeni cech $\mathbb{R}^2$ dla zbioru `data.three_gauss` w zależności od architektury sieci.



Rysunek 26: Przebieg dokładności klasyfikacji w kolejnych epokach dla zbioru `data.three_gauss` w zależności od architektury (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 27: Przebieg funkcji straty w kolejnych epokach dla zbioru `data.three_gauss` w zależności od architektury (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).

Wnioski. Podsumowując badanie wpływu głębokości i szerokości modelu `MLP`:

- W tych konkretnych zadaniach, model bez warstw ukrytych (liniowy) nieco gorzej od sieci głębszych. Dla zbiory `data.simple` podział jest na tyle prosty, że model liniowy nie popełnia wielu błędów. Z kolei dla `data.three_gauss` szum jest na tyle duży że modele głębokie nie mają szansy daleko prześcignąć modelu liniowego, mimo że uczą się szybciej i osiągają mniejszy błąd.
- Zwiększenie głębokości sieci do 2-4 warstw znacząco przyspiesza tempo zbieżności i obniża błąd treningowy, ale przyrost dokładności powyżej 2 warstw ukrytych jest już mniejszy. Dobrym kompromisem między wielkością sieci i osiąganą dokładnością wydaje się architektura średnia $[2, 32, 16]$. Osiąga ona najwyższy wynik na obu zbiorach (99.33% dla `data.simple` oraz 93.44% dla `data.three_gauss`).
- W zbiorze `data.simple` modele głębokie osiągają niemal zerowe straty treningowe bez widocznego spadku wyników na zbiorze testowym.

4.4 Eksperyment 3 - Wpływ funkcji straty

W tym eksperymencie zbadano wpływ doboru funkcji straty na proces uczenia oraz jakość klasyfikacji. Porównano dwie funkcje celu: entropię krzyżową (`Cross-Entropy`: `BinaryCrossEntropy` + aktywacja wyjściowa `Sigmoid` dla klasyfikacji binarnej oraz

`CategoricalCrossEntropy` + aktywacja wyjściowa `Softmax` dla wieloklasowej) oraz błąd średniokwadratowy (`MSE`). Pozostałe elementy sieci ustalono na podstawie wyników dwóch poprzednich eksperymentów:

- architektura $[2, 32, 16, \text{wyjście}]$
- warstwy ukryte z aktywacją `ReLU` i inicjalizacją `He`

Aby dokładniej sprawdzić zachowanie miar błedu, przetestowano trzy wartości współczynnika uczenia: $\eta \in \{0.01, 0.05, 0.2\}$. Wyniki uśredniono z 3 ziaren losowych.

4.4.1 Zbiór danych simple

Wyniki dokładności klasyfikacji na zbiorze binarnym `data.simple` zestawiono w Tabeli 9. `Cross-Entropy` osiąga wysoką dokładność już przy najniższym kroku uczenia $\eta = 0.01$ (99.67%). W przypadku błędu średniokwadratowego (`MSE`) przy małym kroku $\eta = 0.01$ sieć radzi sobie zauważalnie słabiej (97.33%). Dopiero zwiększenie kroku uczenia do $\eta = 0.05$ lub $\eta = 0.2$ pozwala modelowi z funkcją `MSE` dorównać wynikom `Cross-Entropy`.

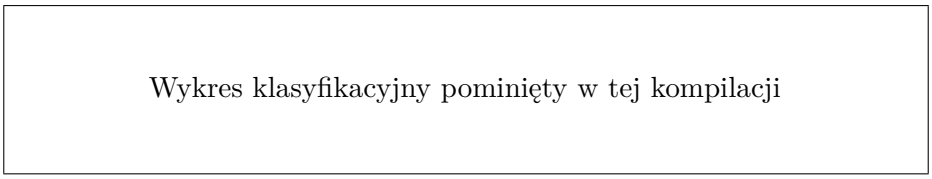
Tabela 9: Dokładność klasyfikacji w zależności od funkcji straty i współczynnika uczenia η dla zbioru `data.simple` (średnia ± odchylenie standardowe z 3 ziaren).

Funkcja straty	**Krok uczenia (η)**	**Zbiór testowy [%]**	**Zbiór uczący [%]**
`Cross-Entropy`	0.01	$\mathbf{99.67 \pm 0.47}$	99.00 ± 1.41
`Cross-Entropy`	0.05	$\mathbf{99.67 \pm 0.47}$	100.00 ± 0.00
`Cross-Entropy`	0.20	99.33 ± 0.47	100.00 ± 0.00
`MSE`	0.01	97.33 ± 1.25	98.00 ± 1.41
`MSE`	0.05	$\mathbf{99.67 \pm 0.47}$	100.00 ± 0.00
`MSE`	0.20	99.33 ± 0.47	100.00 ± 0.00

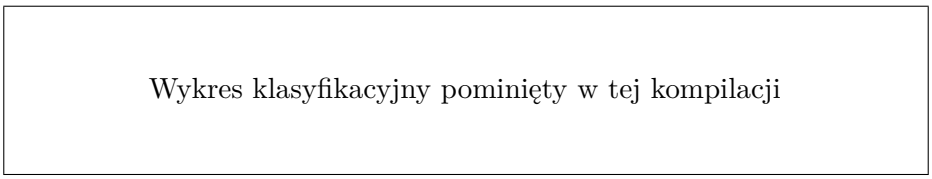
Na Rysunku 28 przedstawiono wyznaczone granice decyzyjne. Obie funkcje straty poprawnie rozdzielają zbiór, jednak dla `MSE` przy $\eta = 0.01$ granica jest mniej gładka i widać większe niezdecydowanie modelu w pobliżu punktów skrajnych. Przy wyższych współczynnikach uczenia granice stają się ostre i bardzo pewne w obu przypadkach.

Przebieg dokładności (Rysunek 29) oraz straty (Rysunek 30) ujawnia wyraźną przewagę tempa uczenia na korzyść `Cross-Entropy`. Model z `Cross-Entropy` osiąga niemal maksymalną dokładność już w ciągu pierwszych kilkunastu epok, podczas gdy `MSE` przy $\eta = 0.01$ uczy się wolno i z większym rozrzutem pomiędzy ziarnami.

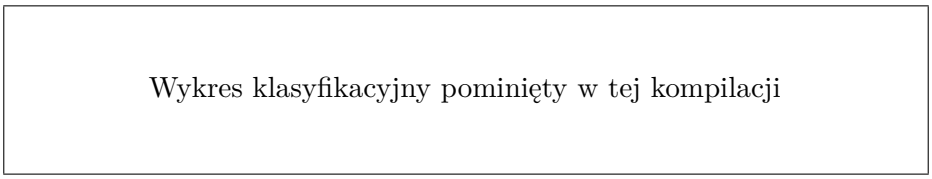
Kluczowe wyjaśnienie tego zachowania widać na wykresie dynamiki aktualizacji wag (Rysunek 31). Dla funkcji `MSE` obserwujemy zjawisko nasycenia gradientu. Pochodna błędu `MSE` względem sygnału wejściowego do neuronu wyjściowego zawiera mnożnik w postaci pochodnej sigmoidy $\sigma'(z)$. Gdy predykcja wyjściowa jest bliska 0 lub 1, pochodna $\sigma'(z)$ dąży do zera, co drastycznie tłumi gradient i sprawia, że poprawki wag $\|\Delta W\|$ są bardzo małe. W przypadku `Cross-Entropy` człon $\sigma'(z)$ skraca się w trakcie wyznaczania gradientu, a sygnał błędu zależy wprost od różnicy $(y_{pred} - y_{true})$, co zapewnia duże i skuteczne aktualizacje od samego początku treningu. Dopiero większy krok uczenia ($\eta = 0.05, 0.2$) w przypadku `MSE` pozwala zrekompensować małe wartości gradientu.



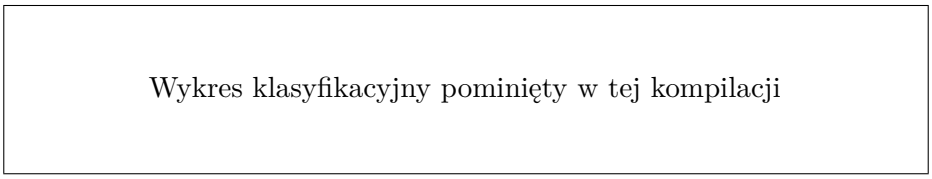
Rysunek 28: Granice decyzyjne w zależności od funkcji straty i kroku uczenia η dla zbioru `data.simple`.



Rysunek 29: Przebieg dokładności klasyfikacji w kolejnych epokach dla funkcji `Cross-Entropy` oraz `MSE` przy różnych wartościach η (`data.simple`, średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 30: Przebieg funkcji straty w kolejnych epokach dla `Cross-Entropy` i `MSE` na rozdzielonych skalach (`data.simple`, średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 31: Dynamika wielkości aktualizacji wag $\|\Delta W\|$ w kolejnych epokach treningu (`data.simple`). Wyraźnie widoczne tłumienie aktualizacji dla `MSE` przy $\eta = 0.01$.

4.4.2 Zbiór danych three_gauss

Wyniki dokładności dla wieloklasowego zbioru `data.three_gauss` z warstwą wyjściową `Softmax` przedstawiono w Tabeli 10. Tak jak w poprzednich eksperymentach, ze względu na fizyczne nakładanie się rozkładów gaussowskich, żaden model nie przekracza progu ok. 93.2%.

Nową obserwacją jest to, że w problemie wieloklasowym różnice w końcowej dokładności pomiędzy `Cross-Entropy` a `MSE` są jeszcze mniejsze: zarówno `Cross-Entropy`, jak i `MSE` osiągają ok. $93.0 - 93.2\%$ na zbiorze testowym. Niemniej jednak, przy małym kroku $\eta = 0.01$ funkcja `MSE` uczy się zauważalnie wolniej na zbiorze treningowym (91.44% wobec 92.89% dla `Cross-Entropy`), co wskazuje na występowanie analogicznego zjawiska spłaszczenia gradientu przez pochodną funkcji `Softmax`.

Tabela 10: Dokładność klasyfikacji w zależności od funkcji straty i współczynnika uczenia η dla zbioru `data.three_gauss` (średnia ± odchylenie standardowe z 3 ziaren).

Funkcja straty	**Krok uczenia (η)**	**Zbiór testowy [%]**	**Zbiór uczący [%]**
`Cross-Entropy`	0.01	93.11 ± 0.16	92.89 ± 0.16
`Cross-Entropy`	0.05	$\mathbf{93.22 \pm 0.16}$	94.11 ± 0.16
`Cross-Entropy`	0.20	$\mathbf{93.22 \pm 0.42}$	94.78 ± 0.57
`MSE`	0.01	93.00 ± 0.00	91.44 ± 1.03
`MSE`	0.05	93.11 ± 0.42	93.00 ± 0.27
`MSE`	0.20	93.00 ± 0.27	93.89 ± 0.42

Na Rysunku 32 zobrazowano granice decyzyjne dla badanych wariantów. Dla obu funkcji straty przy krokach $\eta = 0.05$ i $\eta = 0.2$ granice prawidłowo wyodrębniają trzy obszary, a punkty błędnie zaklasyfikowane leżą wyłącznie w rejonie wzajemnego przenikania się klas w centrum. Pozostałe wykresy (Rysunki 33, 34 oraz 35) prezentują zbliżone zjawiska i wnioski będą analogiczne jak dla zbioru `data.simple`.

Wykres klasyfikacyjny pominięty w tej kompilacji

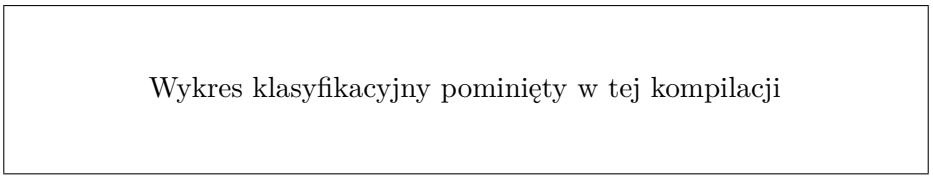
Rysunek 32: Granice decyzyjne w zależności od funkcji straty i kroku uczenia η dla zbioru `data.three_gauss`.

Wykres klasyfikacyjny pominięty w tej kompilacji

Rysunek 33: Przebieg dokładności klasyfikacji w kolejnych epokach dla zbioru `data.three_gauss` (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).

Wykres klasyfikacyjny pominięty w tej kompilacji

Rysunek 34: Przebieg funkcji straty w kolejnych epokach dla zbioru `data.three_gauss` (średnia z 3 ziaren z przedziałem $\pm 1\sigma$).



Rysunek 35: Dynamika wielkości aktualizacji wag $\|\Delta W\|$ w kolejnych epokach treningu (`data.three_gauss`).

Wnioski. Podsumowując porównanie `Cross-Entropy` oraz błędu średniokwadratowego (`MSE`) w zadaniach klasyfikacji:

- **Przewaga `Cross-Entropy`**: Entropia krzyżowa jest lepiej dopasowana do zadań klasyfikacyjnych. Zapewnia szybszą zbieżność i wysoką dokładność już przy małych wartościach kroku uczenia ($\eta = 0.01$).
- **Zjawisko nasycenia w `MSE`**: Zastosowanie funkcji `MSE` prowadzi do spłaszczenia gradientu w pobliżu nasyconych stanów wyjścia (gdy wyjście jest bliskie 0 lub 1). Obecność pochodnej $\sigma'(z)$ w gradiencie drastycznie zmniejsza poprawki wag $\|\Delta W\|$, przez co sieć uczy się powoli w początkowych fazach.
- **Wpływ współczynnika uczenia**: Wolniejsze uczenie modelu z funkcją `MSE` można częściowo skompensować poprzez zwiększenie wartości η (np. do 0.05 lub 0.2). Przy większym kroku uczenia sieć z funkcją `MSE` osiąga ostatecznie zbliżoną dokładność do modelu z `Cross-Entropy`. Mimo to, entropia kryżowa ma tę przewagę że nie musimy ręcznie dostrajać współczynnika uczenia.

4.5 Podsumowanie i wnioski z części klasyfikacyjnej

- **Funkcja aktywacji**: Najlepsze rezultaty zapewnia funkcja `ReLU` (w połączeniu z inicjalizacją `He` - zgodnie z [1]). Zabezpiecza ona model przed zanikaniem gradientu i gwarantuje najszybszą zbieżność w porównaniu do nasycającej funkcji funkcji `Sigmoid`.
- **Architektura sieci**: Zwiększenie liczby warstw ukrytych przyspiesza proces uczenia i pozwala wyznaczać dokładniejsze granice decyzyjne. Najlepszym kompromisem pomiędzy rozmiarem sieci a dokładnością okazała się architektura 2-warstwowa ($[2, 32, 16]$) — dalsze pogłębianie modelu przynosiło niewielki zysk na zbiorze testowym.
- **Funkcja straty**: Entropia krzyżowa (`Cross-Entropy`) jest lepszym wyborem niż `MSE` dla problemu klasyfikacji. Eliminuje problem nasycenia gradientu na wyjściu z aktywacją `Sigmoid` lub `Softmax`, co zapewnia szybkie i stabilne uczenie już przy małym kroku η.

5 Podsumowanie ogólne i wnioski końcowe

Literatura

[1] The Deep Hub, *He and Xavier Weight Initialization Functions*, `https://medium.com/thedeephub/he-and-xavier-weight-initialization-functions-acedc5322ce5`.